

0

# Processos

## Estocásticos

31/08/2026

- mauriciodaros.github.io/stochastic-processes
- exercícios no site (não é pra entregar!)
- monitoria com Jailson: Quintas, 17:00 - 18:00, sala 408.
- provas: 5 de Outubro, 2 de Dezembro, 16:00 - 19:00, sala 308.

4 maneiras de lidar com dependência:

- Cadeias de Markov
- Martingais
- Campos aleatórios
- Exchangeability (Permutabilidade)

# ① Processos Estocásticos

Dia 31/08/2026

## Revisão Cadeias de Markov

Def:  $(X_n)_{n \in \mathbb{N}}$  em  $I$  é Markov  $(\lambda, P)$  se

- $P(X_0 = i) = \lambda_i$
- $P(X_{n+1} = i_{n+1} | X_n = i_n, \dots, X_0 = i_0) = \underbrace{P(X_{n+1} = i_{n+1} | X_n = i_n)}_{P_{i_n i_{n+1}}}$

Def:  $\tau$  em  $\mathbb{N} \cup \{+\infty\}$  é tempo de parada se  $\{\tau = n\} \in \mathcal{F}_n \forall n \geq 0$


$$\mathcal{F}_n = \sigma(X_0, \dots, X_n)$$

$$\mathcal{F}_\tau = \sigma(\{B \in \mathcal{F} : B \cap \{\tau = n\} \in \mathcal{F}_n, \forall n \in \mathbb{N}\})$$

Teorema:  $(X_{\tau+n})_{n \in \mathbb{N}} | X_\tau = i \sim \text{Markov}(\delta_i, P)$   
e  $(X_{\tau+n})_{n \in \mathbb{N}}$  é indep. de  $X_1, \dots, X_{\tau-1}$ .

Def  $C \subseteq I$

- $C$  fechado
- $C$  comunicante
- Irredutível = fechado + comunicante



②  $p_{ij} = P(T_j < \infty | X_0 = i)$  ,  $T_j = \inf\{n \in \mathbb{N} : X_n = j\}$

Def:  $i \in I$  é recorrente se  $p_{ii} = 1$   
transiente se  $p_{ii} < 1$

Def: •  $N_i = \sum_{n=0}^{\infty} \mathbb{1}_{\{X_n = i\}}$

•  $g_{ij} = E(N_j | X_0 = i)$

Def:  $\pi$  é distribuição estacionária se " $\pi P = \pi$ "


•  $m_j = E[T_j | X_0 = j]$  •  $N_j^{(n)} = \sum_{m=0}^n \mathbb{1}_{\{X_m = j\}}$

Def:  $j \in I$

- Positivo recorrente se  $m_j < \infty$
- Nulo recorrente se  $m_j = \infty$

Teo:  $j$  recorrente  $\Rightarrow \lim_{n \rightarrow \infty} \frac{N_j^{(n)}}{n} = \frac{\mathbb{1}_{\{T_j < \infty\}}}{m_j}$

Teo (Decomposição)



③ Teo Markov  $(\lambda, P)$  recorrente, irredutível  $\Rightarrow \exists$  única  $\pi$  estac.  
positiva  $\pi_j = 1/m_j$

---

Teo (Ergódico)  $(X_n)_{n \in \mathbb{N}}$  pos. rec., irr. .  $f: I \rightarrow \mathbb{R}$  limitada

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=0}^n f(X_k) = \sum_{i \in I} f(i) \cdot \pi_i$$

Def: Período de  $i$ :  $d_i = \text{mdc} \{ n \in \mathbb{N}_+ : p_{ii}^{(n)} > 0 \}$

$d_i = 1 \forall i \in I \Rightarrow$  Aperiódica é  $(X_n)_{n \in \mathbb{N}}$ .

Teo: Cadeia irr., pos. rec., aperiódica,  $\pi$  estacionária

$$\Rightarrow \lim_{n \rightarrow \infty} P(X_n = j) = \pi_j, \forall j \in I$$


---

## ④ Markov Chain Monte Carlo (MCMC)

- Monte Carlo
  - Distribuição  $\pi$
  - $X \sim \pi$
  - Quero  $\mathbb{E}_\pi(f(X))$
- Método Monte Carlo:
  - Amostrar  $X_1, \dots, X_n \sim \pi$  iid
  - Usar LGN:  $\frac{1}{n} \sum_{i=1}^n f(X_i) \approx \mathbb{E}_\pi(f(X))$
- E se amostrar for difícil?
- Markov Chain Monte Carlo:
  - Amostrar  $X_1, \dots, X_n \sim \text{Markov}(\lambda, P)$ , onde  $\pi$  é estacionária
  - Teo. Ergódico  $\Rightarrow \frac{1}{n} \sum_{i=1}^n f(X_i) \approx \mathbb{E}_\pi(f(X))$

### Exemplo: Modelo de Ising

- $G_n = (V(G_n), E(G_n))$
- $I = \{-1, +1\}^{V(G_n)}$
- $\pi(\sigma) = \frac{1}{Z} \exp\left(\beta \sum_{(i,j) \in E(G_n)} \sigma_i \sigma_j\right)$
- $Z$  é constante t.q.  $\sum_{\sigma \in I} \pi(\sigma) = 1$ .
- $\beta$  é a temperatura inversa



medida de Gibbs  
 $\approx$  Markov em índices  
espaciais

$$\begin{aligned}
 \textcircled{5} \quad \pi(\sigma_i = +1 \mid \sigma_{-i} = x_{-i}) &= \frac{\pi(\sigma_i = 1, \sigma_{-i} = x_{-i})}{\pi(\sigma_{-i} = x_{-i}, \sigma_i = +1) + \pi(\sigma_{-i} = x_{-i}, \sigma_i = -1)} \\
 &= \frac{1}{1 + \frac{\pi(\sigma_i = +1, \sigma_{-i} = x_{-i})}{\pi(\sigma_i = -1, \sigma_{-i} = x_{-i})}} = \frac{1}{1 + \exp(-2\beta \sum_{j: j \sim i} x_j)}
 \end{aligned}$$

### Glauber Dynamics / Gibbs-Sampling

•  $Z$  é difícil de calcular

• Seja  $X_0, X_1, \dots$  em  $I$

– " $X_0 \sim \text{Unif}(I)$ " ou qualquer outra coisa

–  $\forall k \geq 1$ , selecione  $v_k \sim \text{Unif}(V(G_n))$ . Dado  $X_k$ ,

Faça  $(X_{k+1})_{-v_k} = X_k$  e  $X$

$$(X_{k+1})_{v_k} = \begin{cases} +1 & \text{com prob. } \pi(\sigma_{v_k} = +1 \mid \sigma_{-v_k} = (X_k)_{-v_k}) \\ -1 & \text{com prob. } \pi(\sigma_{v_k} = -1 \mid \sigma_{-v_k} = (X_k)_{-v_k}) \end{cases}$$

•  $(X_n)_{n \in \mathbb{N}}$  é Cadeia de Markov.

Prop:  $\pi$  é estacionária para  $(X_n)_{n \in \mathbb{N}}$ .

dem: Suponha  $X_0 \sim \pi$ .

$$\mathbb{P}(X_1 = x) = \sum_{j \in V(G_n)} \sum_{x' \in I} \mathbb{P}(X_1 = x \mid v_0 = j, X_0 = x') \mathbb{P}(v_0 = j, X_0 = x')$$

⑥

$$= \sum_{j \in V(G_n)} \sum_{\substack{x' \in I \\ x'_j = x_j}} \mathbb{P}(\text{---}) \mathbb{P}(\text{---})$$

$$= \sum_{j \in V(G_n)} \sum_{\substack{x' \in I \\ x'_j = x_j}} \pi(\sigma_j = x_j \mid \sigma_{-j} = x_{-j}) \cdot \frac{1}{|V(G_n)|} \pi(\sigma = x')$$

$$= \sum_{j \in V(G_n)} \pi(\sigma_j = x_j \mid \sigma_{-j} = x_{-j}) \frac{1}{|V(G_n)|} \pi(\sigma_{-j} = x_{-j})$$

$$= \sum_{j \in V(G_n)} \pi(\sigma_j = x) \frac{1}{|V(G_n)|}$$

$$= \pi(\sigma = x)$$

□

---

Prop:  $(X_n)_{n \in \mathbb{N}}$  é aperiódica, irr., pos. rec.

---

Cor:  $\lim_{n \rightarrow \infty} \mathbb{P}(X_n = x) = \pi(\sigma = x).$